```
#importando as biblioteca necessárias para a análise
import pandas as pd
import matplotlib.pyplot as plt
plt.style.use("seaborn")
import seaborn as sns
```

```
C:\Users\Filipe\AppData\Local\Temp/ipykernel_69336/1094541302.py:4: MatplotlibDeprecationWarning: The seaborn styles shipped by Matplotlib are deprecated since 3.6, as they no longer corre
spond to the styles shipped by seaborn. However, they will remain available as 'seaborn-v0_8-<style>'. Alternatively, directly use the seaborn API instead.
  plt.style.use("seaborn")
```

```
#importando o dataframe que iremos analisar
df = pd.read_csv("churn.csv", index_col='RowNumber')
```

```
df.head()
```

RowNumber	CustomerId	Surname	CreditScore	Geography	Gender	Age	Tenure	Balance	NumOfProducts	HasCrCard	IsActiveMember	EstimatedSalary	Exited
1	15634602	Hargrave	619	France	Female	42	2	0.00	1	1	1	101348.88	1
2	15647311	Hill	608	Spain	Female	41	1	83807.86	1	0	1	112542.58	0
3	15619304	Onio	502	France	Female	42	8	159660.80	3	1	0	113931.57	1
4	15701354	Boni	699	France	Female	39	1	0.00	2	0	0	93826.63	0
5	15737888	Mitchell	850	Spain	Female	43	2	125510.82	1	1	1	79084.10	0

```
#Primeiro vamos verificar informações importantes do nosso dataframe
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 10000 entries, 1 to 10000
Data columns (total 13 columns):
 #   Column           Non-Null Count  Dtype
---  ------           --------------  -----
 0   CustomerId       10000 non-null  int64
 1   Surname          10000 non-null  object
 2   CreditScore      10000 non-null  int64
 3   Geography        10000 non-null  object
 4   Gender           10000 non-null  object
 5   Age              10000 non-null  int64
 6   Tenure           10000 non-null  int64
 7   Balance          10000 non-null  float64
 8   NumOfProducts    10000 non-null  int64
 9   HasCrCard        10000 non-null  int64
 10  IsActiveMember   10000 non-null  int64
 11  EstimatedSalary  10000 non-null  float64
 12  Exited           10000 non-null  int64
dtypes: float64(2), int64(8), object(3)
memory usage: 1.1+ MB
```

Podemos verificar que não existem valores nulos em nosso dataframe, todos as 10 mil entradas estão devidamente preenchidas com algum valor.

Um resumo do que elas signficam:

CustomerId: identificação do cliente.

Surname: sobrenome do cliente.

CreditScore: pontuação de credito, 0 alto risco de inadimplência e 1000 clientes com baixo risco de inadimplência.

Geography: país que o serviço é oferecido.

Gender: sexo do cliente.

Age: idade do cleinte.

Tenure: um indicativo de estabilidade no emprego, em que 0 significa pouca estabilidade e 10 muita estabilidade.

Balance: saldo da conta corrente.

NumOfProducts: número de produtos bancários adquiridos.

HasCrCard: se tem cartão de credito ou não, (Sim = 1 e Não = 0).

IsActiveMember: se é um cliente com conta ativa, (Ativo = 1).

EstimatedSalary: salário estimado.

Exited: cliente deixou de ser cliente do banco ou não (Churn = 1).

Como informado na introdução desse relatório, nossa análise busca entender o perfil dos clientes que deixaram o banco, para isso vamos filtrar nosso dataframe, retornando apenas clientes que saíram(Exited = 1) Para isso vamos utilizar o método query.

```
#Retornar todas pessoas que deixaram de ser clientes
df.query('Exited == 1')
```

RowNumber	CustomerId	Surname	CreditScore	Geography	Gender	Age	Tenure	Balance	NumOfProducts	HasCrCard	IsActiveMember	EstimatedSalary	Exited
1	15634602	Hargrave	619	France	Female	42	2	0.00	1	1	1	101348.88	1
3	15619304	Onio	502	France	Female	42	8	159660.80	3	1	0	113931.57	1
6	15574012	Chu	645	Spain	Male	44	8	113755.78	2	1	0	149756.71	1
8	15656148	Obinna	376	Germany	Female	29	4	115046.74	4	1	0	119346.88	1
17	15737452	Romeo	653	Germany	Male	58	1	132602.88	1	1	0	5097.67	1
...	...	...	...	...	...	...	...	...	...	...	...	...	...
9982	15672754	Burbidge	498	Germany	Male	42	3	152039.70	1	1	1	53445.17	1
9983	15768163	Griffin	655	Germany	Female	46	7	137145.12	1	1	0	115146.40	1
9992	15769959	Ajuluchukwu	597	France	Female	53	4	88381.21	1	1	0	69384.71	1
9998	15584532	Liu	709	France	Female	36	7	0.00	1	0	1	42085.58	1
9999	15682355	Sabbatini	772	Germany	Male	42	3	75075.31	2	1	0	92888.52	1

2037 rows × 13 columns

Podemos perceber que as pessoas que deixaram de ser clientes representam pouco mais de 20% do nosso dataframe. Como o foco da análise são os clientes que saíram(exited = 1), vou definir um novo dataframe com o nome df_churn apenas com esse filtro.

```
df_churn = df.query('Exited == 1')
df_churn
```

RowNumber	CustomerId	Surname	CreditScore	Geography	Gender	Age	Tenure	Balance	NumOfProducts	HasCrCard	IsActiveMember	EstimatedSalary	Exited
1	15634602	Hargrave	619	France	Female	42	2	0.00	1	1	1	101348.88	1
3	15619304	Onio	502	France	Female	42	8	159660.80	3	1	0	113931.57	1
6	15574012	Chu	645	Spain	Male	44	8	113755.78	2	1	0	149756.71	1
8	15656148	Obinna	376	Germany	Female	29	4	115046.74	4	1	0	119346.88	1
17	15737452	Romeo	653	Germany	Male	58	1	132602.88	1	1	0	5097.67	1
...	...	...	...	...	...	...	...	...	...	...	...	...	...
9982	15672754	Burbidge	498	Germany	Male	42	3	152039.70	1	1	1	53445.17	1
9983	15768163	Griffin	655	Germany	Female	46	7	137145.12	1	1	0	115146.40	1
9992	15769959	Ajuluchukwu	597	France	Female	53	4	88381.21	1	1	0	69384.71	1
9998	15584532	Liu	709	France	Female	36	7	0.00	1	0	1	42085.58	1
9999	15682355	Sabbatini	772	Germany	Male	42	3	75075.31	2	1	0	92888.52	1

2037 rows × 13 columns

A partir de agora vamos trabalhar com o dataframe acima

```
df_churn.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 2037 entries, 1 to 9999
Data columns (total 13 columns):
 #   Column           Non-Null Count  Dtype
---  ------           --------------  -----
 0   CustomerId       2037 non-null   int64
 1   Surname          2037 non-null   object
 2   CreditScore      2037 non-null   int64
 3   Geography        2037 non-null   object
 4   Gender           2037 non-null   object
 5   Age              2037 non-null   int64
 6   Tenure           2037 non-null   int64
 7   Balance          2037 non-null   float64
 8   NumOfProducts    2037 non-null   int64
 9   HasCrCard        2037 non-null   int64
 10  IsActiveMember   2037 non-null   int64
 11  EstimatedSalary  2037 non-null   float64
 12  Exited           2037 non-null   int64
dtypes: float64(2), int64(8), object(3)
memory usage: 222.8+ KB
```

Com essas informações preliminares, vamos organizar os dados, separando as variáveis qualitativas e quantitativas. Iremos apagar a coluna CustomerID que é apenas uma identificação do cliente, o RowNumber já está servindo como nosso indexador, e também vou apagar o Surname, que propriamente dito é o sobrenome do cliente.

```
#criando uma lista com as colunas que iremos deletar e deletando as mesmas em seguida

arr_delete = ['CustomerId', 'Surname']

df_churn.drop(arr_delete, axis=1, inplace = True)


#Criando listas com o nome de cada coluna

arr_quali = ['Geography', 'Gender', 'HasCrCard', 'IsActiveMember', 'Exited']
arr_quanti = ['CreditScore', 'Age', 'Tenure', 'Balance', 'NumOfProducts', 'EstimatedSalary', 'Exited']

#criando novos dataframes com base nas listas.
df_churn_quali = df_churn[arr_quali]
df_churn_quanti = df_churn[arr_quanti]
```

```
C:\Users\Filipe\AppData\Local\Temp/ipykernel_69336/3519490126.py:5: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
  df_churn.drop(arr_delete, axis=1, inplace = True)
```

Vamos analisar algumas métricas estatísticas com nossas variáveis quantitativas

```
df_churn_quanti.describe().round(2)
```

	CreditScore	Age	Tenure	Balance	NumOfProducts	EstimatedSalary	Exited
count	2037.00	2037.00	2037.00	2037.00	2037.00	2037.00	2037.0
mean	645.35	44.84	4.93	91108.54	1.48	101465.68	1.0
std	100.32	9.76	2.94	58360.79	0.80	57912.42	0.0
min	350.00	18.00	0.00	0.00	1.00	11.58	1.0
25%	578.00	38.00	2.00	38340.02	1.00	51907.72	1.0
50%	646.00	45.00	5.00	109349.29	1.00	102460.84	1.0
75%	716.00	51.00	8.00	131433.33	2.00	152422.91	1.0
max	850.00	84.00	10.00	250898.09	4.00	199808.10	1.0

Alguns dados relevantes:

Média de idade bem próxima a mediana, baixa assimetria nessa variável(Média: 44.8 Mediana 45.0). Clientes que variam de 18 a 84 anos (A variável Age pode ser convertida para qualitativa, caso seja necessário criar um faixa de idade). Desvio padrão do salário(EstimatedSalary) relativamente alto, o que pode ser comum em uma carteira de clientes bancários.

```
#Clientes que saíram e que possuem idade acima da média arredondada(45)
df_churn_quanti.query('Age > 45')
```

RowNumber	CreditScore	Age	Tenure	Balance	NumOfProducts	EstimatedSalary	Exited
17	653	58	1	132602.88	1	5097.67	1
36	475	45	0	134264.04	1	27822.99	1
42	465	51	8	122522.32	1	181297.65	1
44	834	49	2	131394.56	1	194365.76	1
59	511	66	4	0.00	1	1643.11	1
...	...	...	...	...	...	...	...
9925	632	50	5	107959.39	1	6985.34	1
9957	520	46	10	85216.61	1	117369.52	1
9976	610	50	1	113957.01	2	196526.55	1
9983	655	46	7	137145.12	1	115146.40	1
9992	597	53	4	88381.21	1	69384.71	1

1044 rows × 7 columns

```
#Clientes que saíram e que possuem idade abaixo da média(45)
df_churn_quanti.query('Age < 45')
```

RowNumber	CreditScore	Age	Tenure	Balance	NumOfProducts	EstimatedSalary	Exited
1	619	42	2	0.00	1	101348.88	1
3	502	42	8	159660.80	3	113931.57	1
6	645	44	8	113755.78	2	149756.71	1
8	376	29	4	115046.74	4	119346.88	1
23	510	38	4	0.00	1	118913.53	1
...	...	...	...	...	...	...	...
9961	795	33	9	104552.72	1	120853.83	1
9963	702	44	9	0.00	1	59207.41	1
9982	498	42	3	152039.70	1	53445.17	1
9998	709	36	7	0.00	1	42085.58	1
9999	772	42	3	75075.31	2	92888.52	1

993 rows × 7 columns

```
#vamos analisar os jovens
df_churn_quanti.query('Age > 17 & Age < 30')
```

RowNumber	CreditScore	Age	Tenure	Balance	NumOfProducts	EstimatedSalary	Exited
8	376	29	4	115046.74	4	119346.88	1
47	829	27	9	112045.67	1	119708.21	1
87	750	22	3	121681.82	1	128643.35	1
115	721	28	9	154475.54	2	101300.94	1
165	683	29	0	133702.89	1	55582.54	1
...	...	...	...	...	...	...	...
9540	659	29	6	123192.12	1	56971.41	1
9555	779	29	3	46388.16	3	127939.26	1
9573	644	18	7	0.00	1	59645.24	1
9749	627	24	5	102773.20	2	56793.02	1
9826	467	28	10	126315.26	1	32349.29	1

124 rows × 7 columns

Podemos perceber que os jovens representam uma infíma parcela dos antigos clientes do banco, 124 registros, aproximadamente 6%. Podemos visualizar um gráfico com a quantidade por idade

```
df_churn_quanti["Age"].value_counts().sort_values(ascending=True).plot.bar()
plt.title("Churn X idade")
plt.xlabel("Idade")
plt.ylabel("Ex Clientes")
plt.figure(figsize=(9, 4))
```

```
<Figure size 900x400 with 0 Axes>
```

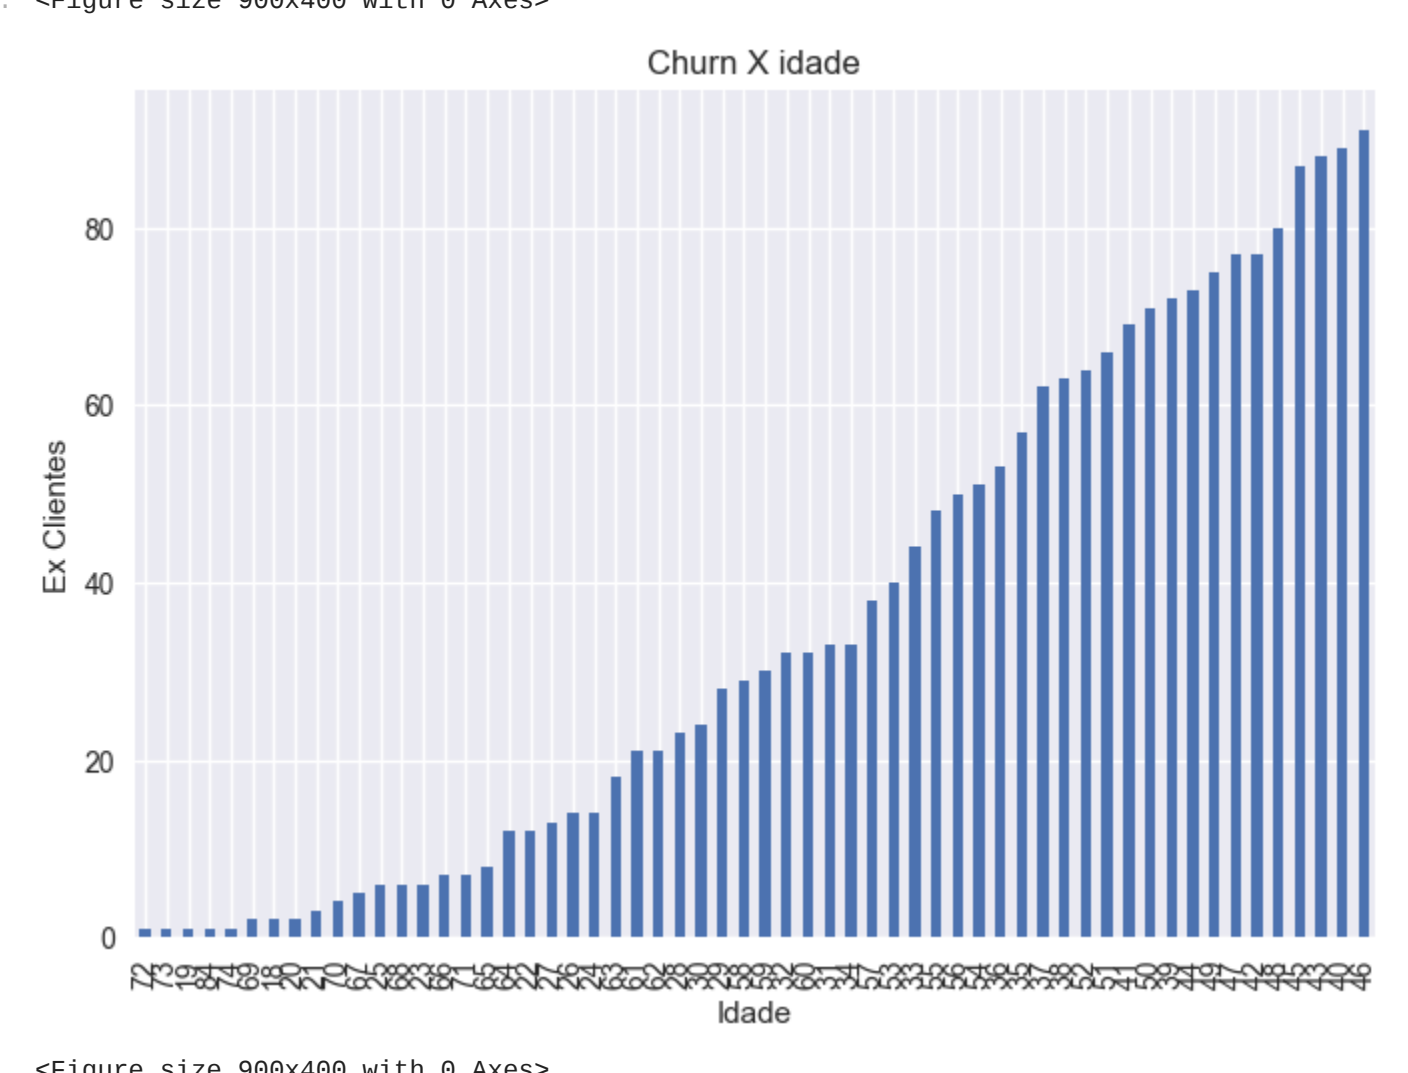


```
<Figure size 900x400 with 0 Axes>
```

Podemos notar que a maioria está na faixa dos 30 a 50 anos

Vamos retornar para o nosso dataframe principal e realizar algumas análises. Para isso vamos exibir uma amostra

```
df_churn.sample(10)
```

RowNumber	CreditScore	Geography	Gender	Age	Tenure	Balance	NumOfProducts	HasCrCard	IsActiveMember	EstimatedSalary	Exited
23	510	Spain	Female	38	4	0.00	1	1	0	118913.53	1
9810	820	France	Female	39	1	104614.29	1	1	0	61538.43	1
5025	745	Germany	Female	44	0	119638.21	1	1	1	34265.08	1
6506	596	Germany	Male	48	2	131326.47	1	0	0	1140.02	1
82	777	France	Female	32	2	0.00	1	1	0	136458.19	1
1952	604	France	Male	53	8	144453.75	1	1	0	190998.96	1
2345	714	Germany	Female	49	4	93059.34	1	1	0	7571.51	1
9749	627	Germany	Male	24	5	102773.20	2	1	0	56793.02	1
4893	707	Germany	Female	51	10	98438.23	1	0	0	70778.63	1
6714	586	France	Female	46	0	0.00	3	0	1	131553.82	1

```
#quantidade de ex clientes por País
df_churn.Geography.value_counts()
```

```
Germany    814
France     810
Spain      413
Name: Geography, dtype: int64
```

```
#visualizando esses dados em gráficos de barra
df_churn.Geography.value_counts().plot.bar()
plt.title('Ex Clientes x País')
plt.xlabel('País')
plt.ylabel('Quantidade de Clientes')
plt.xticks(rotation = 'horizontal');
```

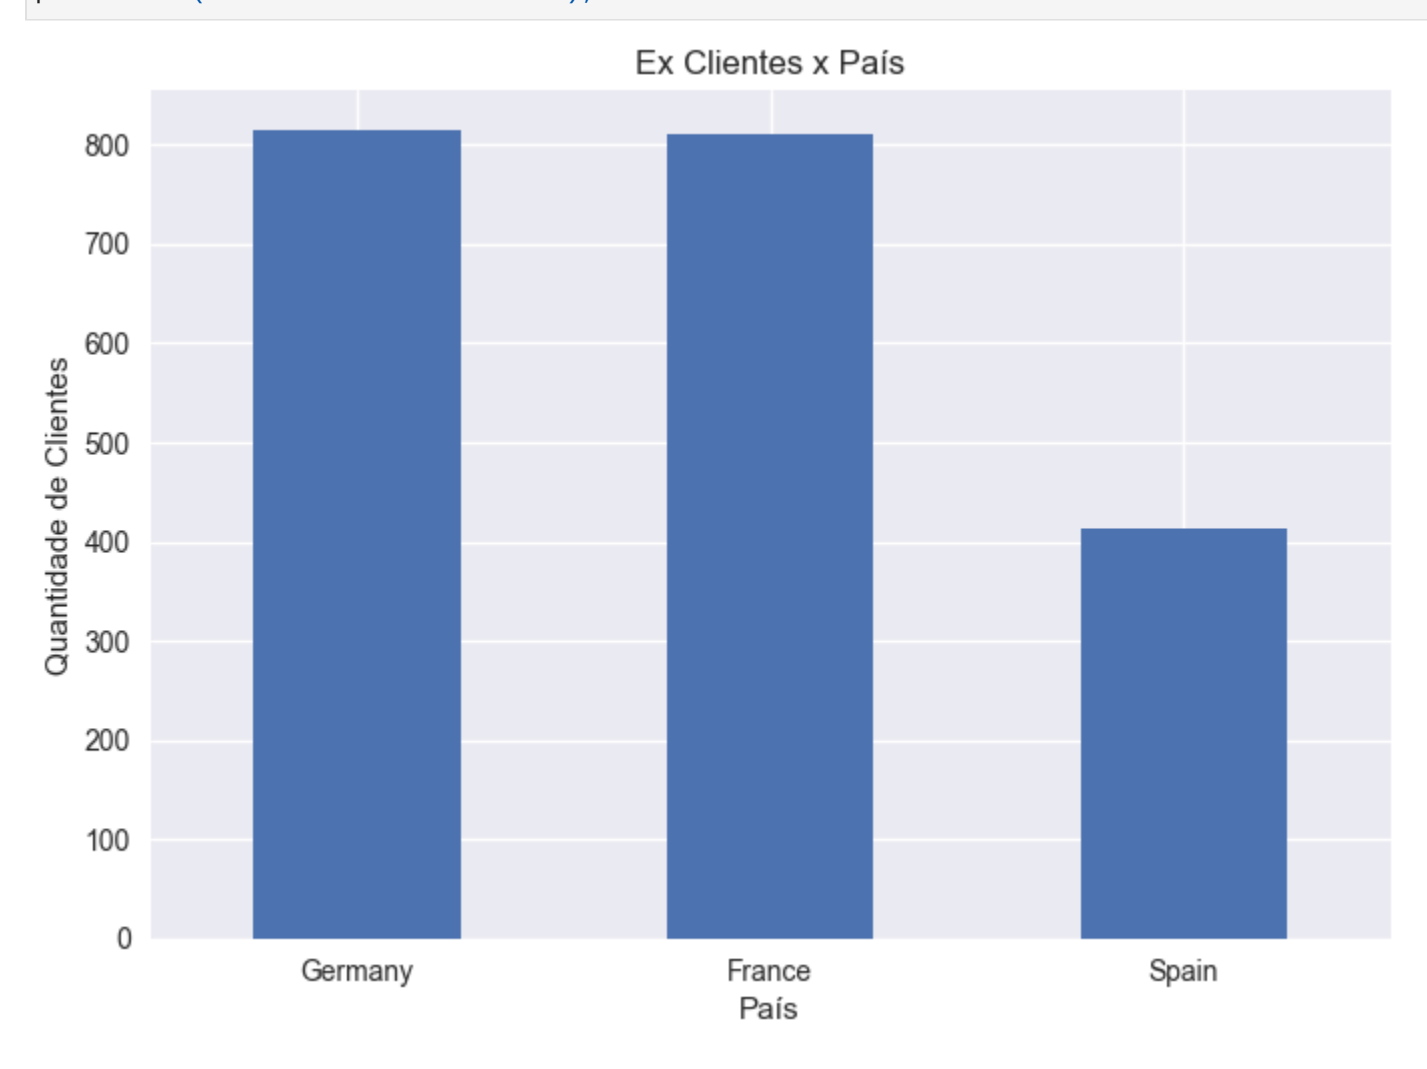

Sabemos que mais da metade dos ex clientes são Alemães ou Franceses, vamos analisar as médias salariais por países

```
#Medias salariais por país
pd.options.display.float_format = '{:,.2f}'.format
round(df_churn.groupby("Geography")["EstimatedSalary"].mean(), 2)
```

```
Geography
France    103,439.28
Germany    98,403.89
Spain     103,629.55
Name: EstimatedSalary, dtype: float64
```

```
round(df_churn.groupby("Geography")["EstimatedSalary"].mean(), 2).plot.barh();
```

```
<AxesSubplot: ylabel='Geography'>
```

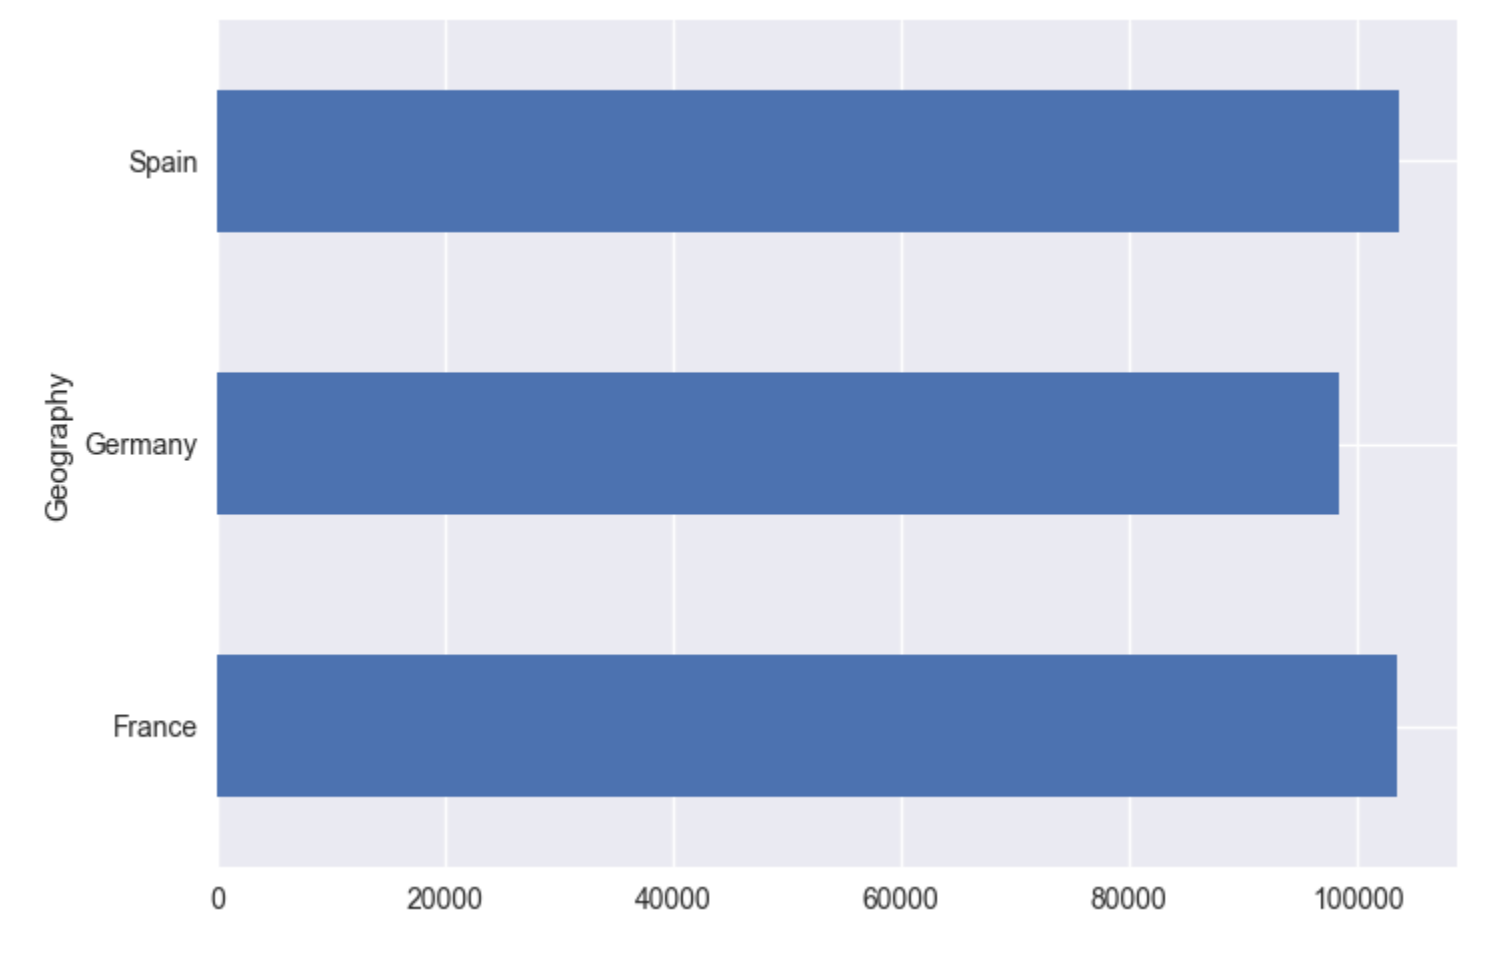

Algumas métricas estátisticas gerais de salário

```
df_churn.EstimatedSalary.describe().round(2)
```

```
count     2,037.00
mean    101,465.68
std      57,912.42
min          11.58
25%      51,907.72
50%     102,460.84
75%     152,422.91
max     199,808.10
Name: EstimatedSalary, dtype: float64
```

25% ganham aproximadamente até 51.907 mil euros por ano 50% ganham aproximadamente até 102.460 mil euros por ano Média está bem próxima da mediana 101.4 e 102.4 respectivamente. Valor mínimo está bem destoante.

```
#Ex cliente com o salário estimado mais baixo
df_churn.query('EstimatedSalary == 11.58')
```

RowNumber	CreditScore	Geography	Gender	Age	Tenure	Balance	NumOfProducts	HasCrCard	IsActiveMember	EstimatedSalary	Exited
2363	709	Germany	Male	45	4	122,917.71	1	1	1	11.58	1

Esse valor corrobora para que a média salarial da alemanha seja menor que as demais, ainda assim mantendo um nível bem próximo da média geral. Agora vamos verificar como estava o índicativo de estabilidade no emprego(Tenure)

```
#média de Tenure
round(df_churn.Tenure.mean(),0)
```

```
5.0
```

```
#Ex clientes com indíce de estabilidade maior que a média
df_churn.query('Tenure > 5')
```

RowNumber	CreditScore	Geography	Gender	Age	Tenure	Balance	NumOfProducts	HasCrCard	IsActiveMember	EstimatedSalary	Exited
3	502	France	Female	42	8	159,660.80	3	1	0	113,931.57	1
6	645	Spain	Male	44	8	113,755.78	2	1	0	149,756.71	1
42	465	France	Female	51	8	122,522.32	1	0	0	181,297.65	1
47	829	Germany	Female	27	9	112,045.67	1	1	1	119,708.21	1
48	637	Germany	Female	39	9	137,843.80	1	1	1	117,622.80	1
...	...	...	...	...	...	...	...	...	...	...	...
9957	520	France	Female	46	10	85,216.61	1	1	0	117,369.52	1
9961	795	Germany	Female	33	9	104,552.72	1	1	1	120,853.83	1
9963	702	Spain	Male	44	9	0.00	1	0	0	59,207.41	1
9983	655	Germany	Female	46	7	137,145.12	1	1	0	115,146.40	1
9998	709	France	Female	36	7	0.00	1	0	1	42,085.58	1

884 rows × 11 columns

```
#Ex clientes com indíce de estabilidade igual ou menor que a média
df_churn.query('Tenure <= 5')
```

RowNumber	CreditScore	Geography	Gender	Age	Tenure	Balance	NumOfProducts	HasCrCard	IsActiveMember	EstimatedSalary	Exited
1	619	France	Female	42	2	0.00	1	1	1	101,348.88	1
8	376	Germany	Female	29	4	115,046.74	4	1	0	119,346.88	1
17	653	Germany	Male	58	1	132,602.88	1	1	0	5,097.67	1
23	510	Spain	Female	38	4	0.00	1	1	0	118,913.53	1
31	591	Spain	Female	39	3	0.00	3	1	0	140,469.38	1
...	...	...	...	...	...	...	...	...	...	...	...
9948	615	France	Male	34	1	83,503.11	2	1	1	73,124.53	1
9976	610	Germany	Male	50	1	113,957.01	2	1	0	196,526.55	1
9982	498	Germany	Male	42	3	152,039.70	1	1	1	53,445.17	1
9992	597	France	Female	53	4	88,381.21	1	1	0	69,384.71	1
9999	772	Germany	Male	42	3	75,075.31	2	1	0	92,888.52	1

1153 rows × 11 columns

Mais da metade dos ex clientes possui tenure igual ou menor a média.

```
array_1 = ['Tenure', 'EstimatedSalary']
df_churn_correlacao = df_churn[array_1]
```

```
#Podemos notar uma correlação moderada entre o Tenure e salário
df_churn_correlacao.corr(method ='pearson')
```

	Tenure	EstimatedSalary
Tenure	1.00	0.05
EstimatedSalary	0.05	1.00

Vamos analisar o sexo dos ex clientes

```
#média de salarial por sexo:
round(df_churn.groupby("Gender")["EstimatedSalary"].mean(), 2)
```

```
Gender
Female   102,948.99
Male      99,584.29
Name: EstimatedSalary, dtype: float64
```

Podemos notar que o público feminino tem a média salarial maior. Vamos verificar a quantidade de homens e mulheres por país

```
df_churn.groupby("Gender")["EstimatedSalary"].mean().plot.bar()
plt.title('Salário por sexo')
plt.xlabel('Sexo')
plt.ylabel('Média anual do Salário')
plt.xticks(rotation = 'horizontal');
```

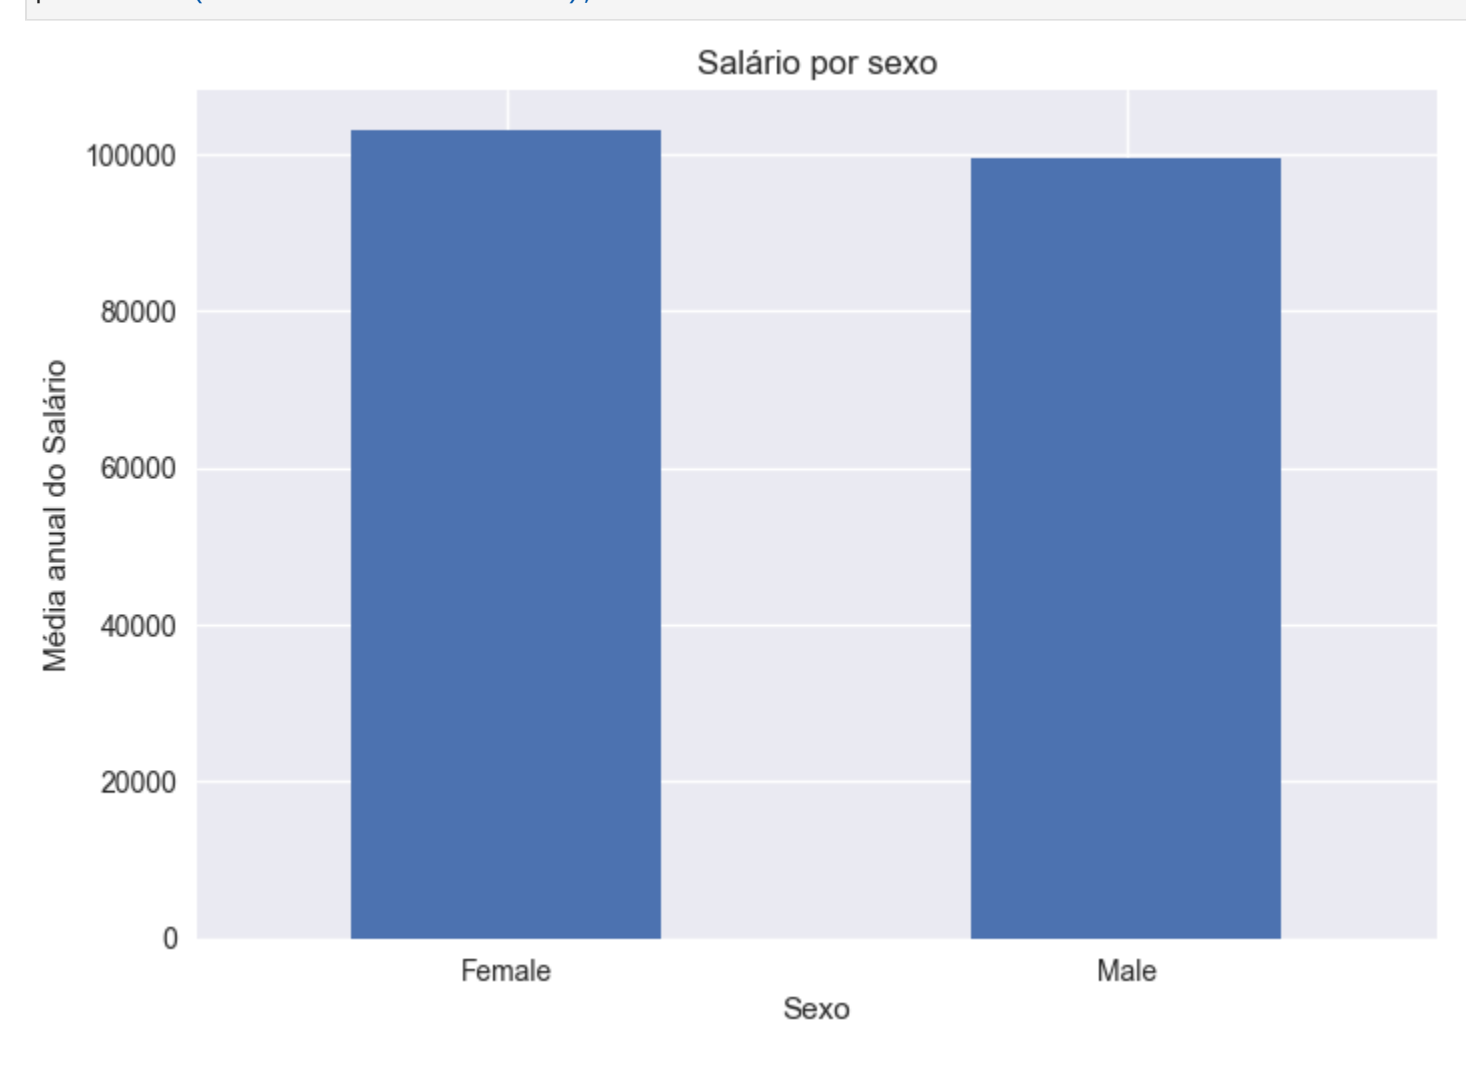


```
df_churn.groupby("Geography")["Gender"].value_counts()
```

```
Geography  Gender
France     Female    460
           Male      350
Germany    Female    448
           Male      366
Spain      Female    231
           Male      182
Name: Gender, dtype: int64
```

```
df_churn.groupby("Geography")["Gender"].value_counts().plot.barh();
plt.title('Sexo por País')
plt.xlabel('Quantidade')
plt.ylabel('País, sexo')
```

```
Text(0, 0.5, 'País, sexo')
```

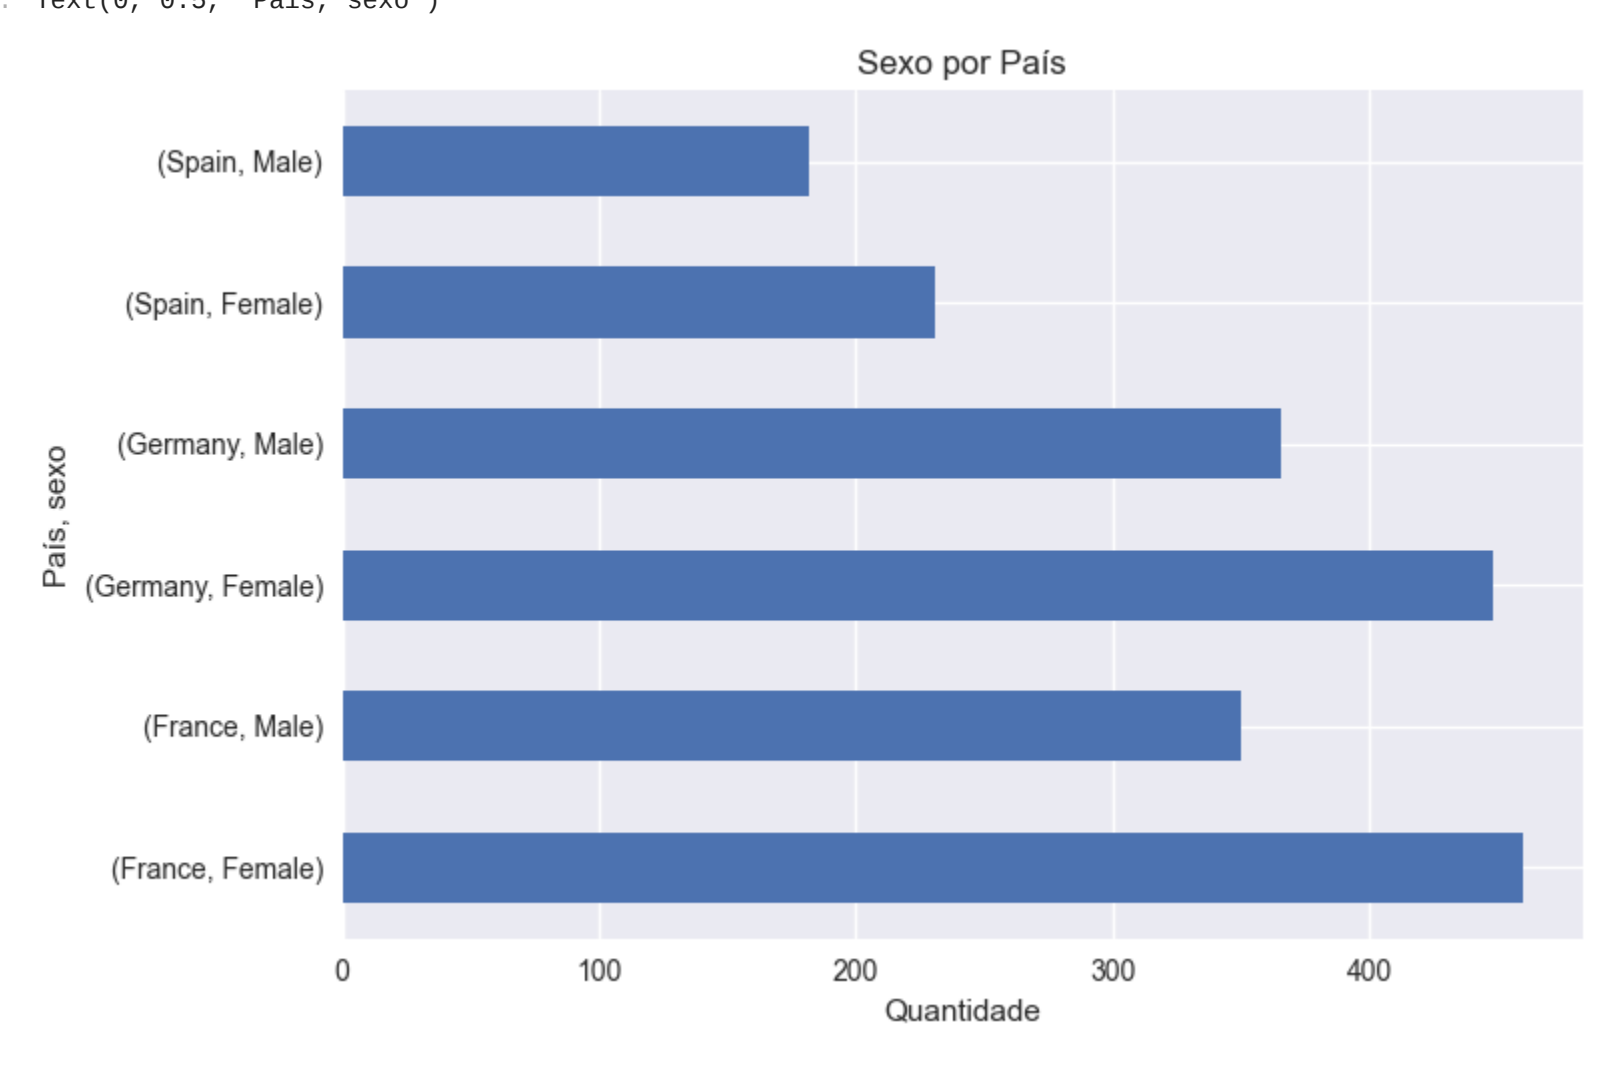

Em contrapartida, os homens possuem mais saldo em conta na média

```
#Média de saldo em conta por sexo
df_churn.groupby("Gender")["Balance"].mean()
```

```
Gender
Female   89,036.64
Male     93,736.48
Name: Balance, dtype: float64
```

```
df_churn.groupby("Tenure")["Balance"].mean()
```

```
Tenure
0    96,054.89
1    89,843.92
2    84,357.17
3    90,152.44
4    87,977.83
5    92,446.42
6    88,239.35
7    92,309.93
8    98,057.32
9    97,156.67
10   85,491.04
Name: Balance, dtype: float64
```

Podemos perceber que o nível de estabilidade não é a causa de ter um saldo em conta maior, ex clientes com tenure abaixo da média possuíam saldos parecidos ao de clientes com tenure mais elevado.

```
df_churn.groupby("Tenure")["Balance"].mean().plot.barh()
plt.title('Tenure X Saldo(Média)')
plt.xlabel("Saldo")
```

```
Text(0.5, 0, 'Saldo')
```

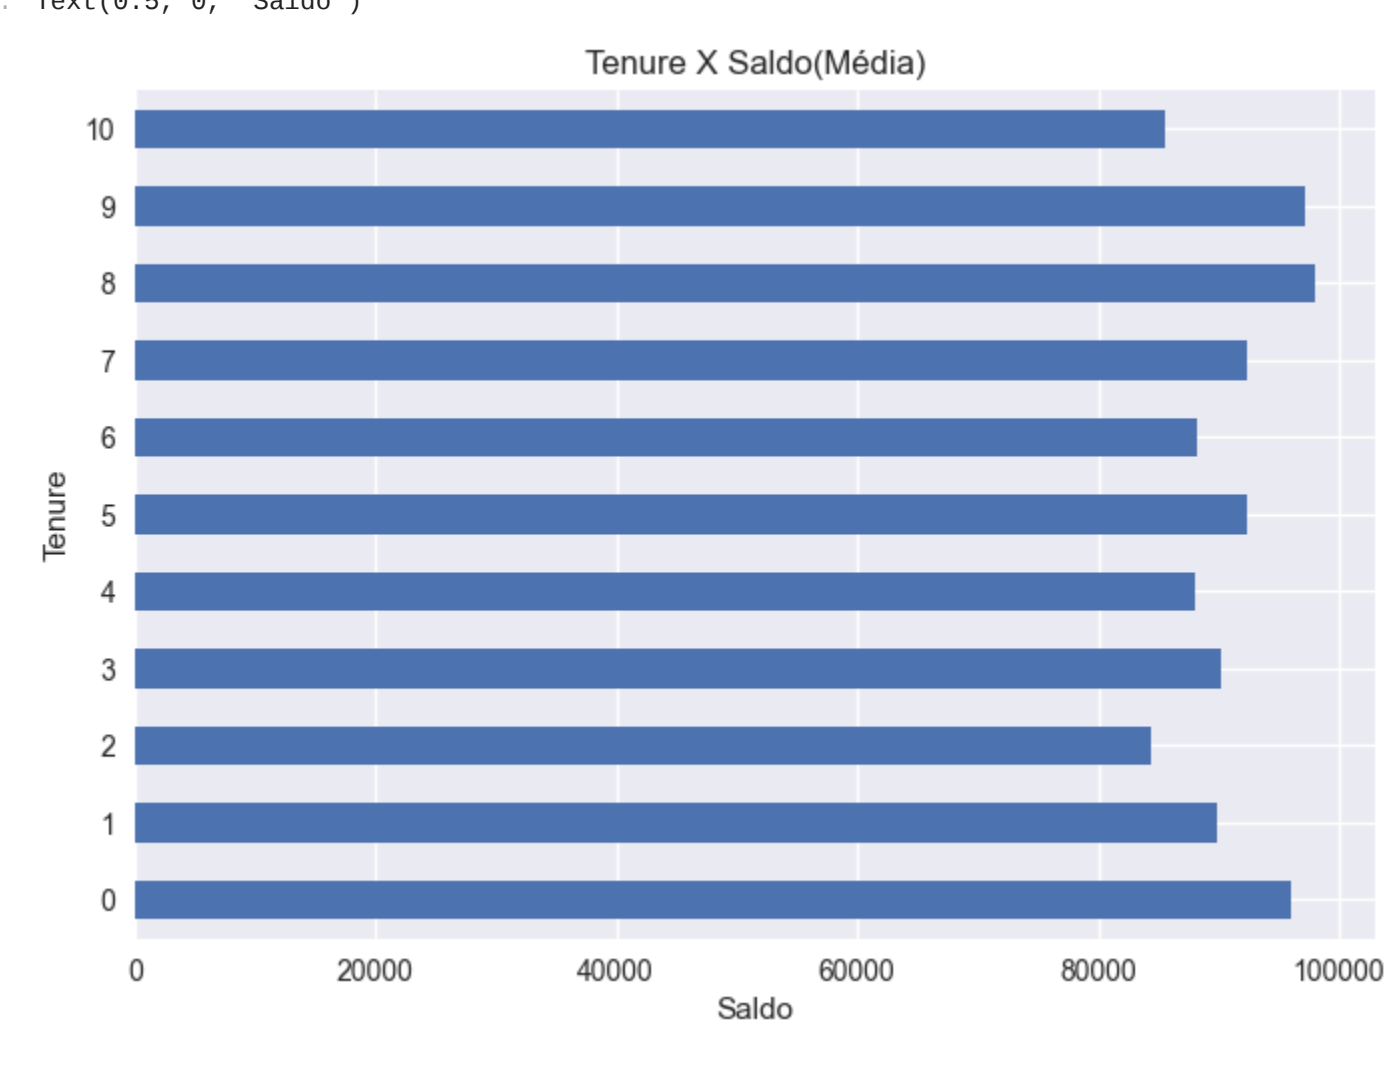

Muito mais pode ser analisando, mas com essa curta análise, podemos identificar que o perfil do cliente que deixou o banco é em sua maioria do sexo feminino, franceses e alemães, de média salaria acima dos 100 mil por ano e em sua maioria acima dos 30 anos.